



# TP5 - *Deep Learning*

---

- De Simone, Franco - 61100
- Dizenhaus, Manuel - 61101
- Cornidez, Milagros - 61432

# Introducción: Autoencoders

- Redes de tipo *Feed Forward* donde se busca que **input == Output**
- Reducción de la dimensionalidad → “*Espacio latente*”
- Particularidad de los autoencoders → Estructura con *encoder* y *decoder*











Ejercicio 1: Imágenes  
binarias de una  
*tipografía.*

# Planteo del problema

- Fuente de datos: Archivo “*fonts.h*” con letras en formato *hexadecimal*.
- Objetivo: “Diseñar un *autoencoder* que permita aprender y representar los símbolos del alfabeto propuesto.”
- Experimentación:
  - Arquitectura del autoencoder: ¿Cantidad de *capas ocultas*?
  - Tamaño del conjunto de entrenamiento: ¿Hay capacidad de generalización?
  - Exploración del espacio latente
- Implementación de un *Denoising Autoencoder*.









# Resultados

- Arquitectura [35, 20, 2, 20, 35]
- Cantidad de iteraciones: 10000
- Eta: 0,0005
- Error: 4,983











# Resultados

- Arquitectura [35, 15, 10, 2, 10, 15, 35]
- Cantidad de iteraciones: 10000
- Eta: 0,0005
- Error: 3,329




# Resultados

- Arquitectura [35, 25, 20, 10, 2, 10, 20, 25, 35]
- Cantidad de iteraciones: 10000
- Eta: 0,0005
- Error: 2,515




# ¿Y probando distintos subconjuntos?


Train set: 4




Train set: 16



Train set: 8



Train set: 32









# Capacidad de generalización


Train:

Test:


Tamaño conjunto  
train: 8














# Espacio latente: 2 dimensiones













# Exploración del Espacio Latente



# Exploración del Espacio Latente




# Exploración del Espacio Latente











# Denoising Autoencoder

El *Denoising Autoencoder* se utiliza para quitar el “ruido” (perturbaciones indeseables) de un conjunto de datos. En este caso, se entrenará a la red para que, ante la aparición de una letra con una pequeña perturbación, sepa devolver la letra original con el menor ruido posible.



# Denoising Autoencoder




# Ejercicio 2:

## Implementación de un Autoencoder Variacional Simple



# ¿Qué son los autoencoders variacionales?


- Autoencoders → **Peligro de overfitting**
- VAEs → Buscan *regularizar* el entrenamiento para evitar *overfitting* y asegurar que el espacio latente tenga buenas propiedades generativas.
- En vez de codificar el input como un punto, se codifica como una distribución normal a lo largo del espacio latente.
- La regularidad esperada del espacio latente tiene dos propiedades centrales:
  - *Continuidad*: Dos puntos cercanos se deben decodificar de manera similar
  - *Compleitud*: Un punto sampleado debe dar información valiosa del contenido



# Pequeña observación del autoencoder variacional simple

- Definimos que la distribución del espacio latente era *normal*
- Puede ocurrir que, si el término regularizador no está bien definido, el modelo puede tender a una *varianza* muy chica (acercándose al overfitting) como también devolver distribuciones con *medias* que estén muy lejanas en el espacio latente.
- Para evitar esto, hay que regularizar la matriz de covarianza y la media de las distribuciones retornadas por el encoder, tratando que se acerquen a una distribución normal






# Dataset escogido: MNIST font




- Conjunto de 60.000 dígitos, en una matriz de 28x28, escritos a mano



# Representación del espacio latente



# Dígitos generados por el VAE



Información  
adicional

# Información interesante: Tendencias actuales

- **Dall-e mini** → Tecnología que es furor en las redes sociales actualmente, está basada en estructuras que estudiamos

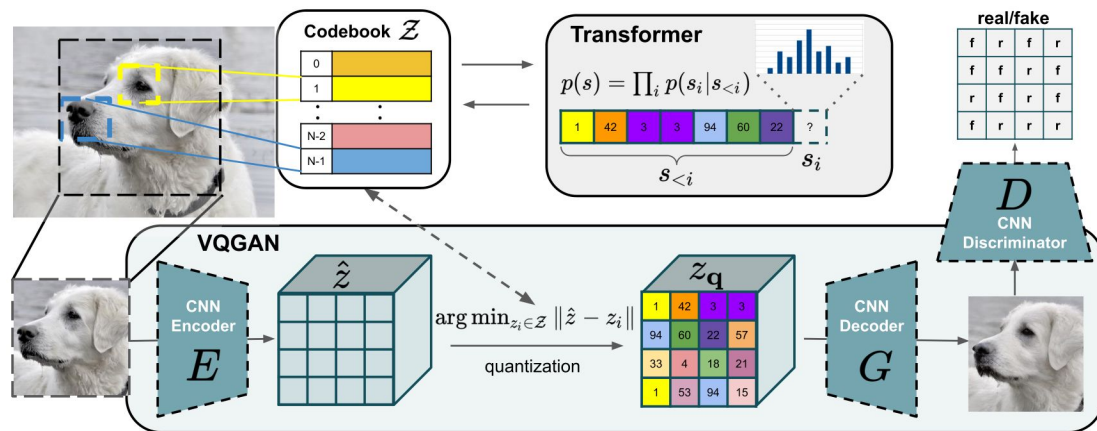
## DALL-E mini

### Generate images from text

What do you want to see?

an avocado armchair flying into space

an avocado armchair flying into space





# Información interesante: Tendencias actuales

**This person does not exist** → Genera, con una Generative Adversarial Network (GAN), rostros humanos de personas que no existen

- StyleGAN: Presentado por NVIDIA en 2018, y lanzado al público en 2019



# Conclusiones

# Conclusiones

- El VAE logra reconstruir la entrada de manera efectiva
- Tiempos de ejecución extremadamente altos para pocas iteraciones
- Cercanía en espacio latente